

Trustworthy-ai-assignment4

2021540010 김정민

1. 모델, 데이터셋, 검증 속성

본 과제에서는 Iris 데이터셋으로 학습한 FC(Fully Connected) 네트워크를 검증 대상 모델로 선택하였다. 모델 구조는 입력층 4 개 노드, 은닉층 8 개 및 16 개 노드(ReLU 활성화), 출력층 3 개 노드(3-class 분류)로 구성되며, ONNX 형식으로 저장하였다.

검증 속성은 클래스 0 에 속하는 샘플 $[0.222, 0.625, 0.068, 0.042]$ 에 대해 l_∞ -ball 기준 $\epsilon=0.01$ 범위 내의 모든 입력이 동일하게 클래스 0 으로 분류되는지 여부이다. 이를 VNNLib 형식으로 명세하여 α, β -CROWN 에 입력하였다.

2. 결과 및 해석

검증 결과는 **unsat** 으로, $\epsilon=0.01$ 범위 내의 모든 입력에 대해 모델이 클래스 0 을 올바르게 분류함이 수학적으로 증명되었다. 즉, 해당 입력 근방에서 adversarial example 이 존재하지 않음이 보장된다. 검증 소요 시간은 약 0.49 초였으며, α -CROWN 의 초기 bound propagation 만으로 검증이 완료되어 branch-and-bound 단계 없이 빠르게 종료되었다.

3. Marabou vs α, β -CROWN 비교

Assignment #3 에서 동일한 모델과 동일한 $\epsilon=0.01$ 조건으로 Marabou 를 사용하여 검증한 결과는 **sat**(반례 발견)이었으나, α, β -CROWN 에서는 **unsat**(검증 성공)이 나왔다. 이는 두 도구의 검증 방식 차이에서 기인한다. Marabou 는 SMT solver 기반으로 정확한 반례를 탐색하는 반면, α, β -CROWN 은 linear relaxation 을 통해 출력 bound 를 계산하므로 수치적 오차가 결과에 영향을 줄 수 있다.

항목	Marabou	α, β -CROWN
결과	Sat(반례 발견)	Unsat (검증 성공)
소요 시간	~24ms	~0.49 초
방식	SMT solver	Linear relaxation + BnB
설정 방식	Python API	YAML + VNNLib
사용 편의성	Python 코드로 직관적	YAML 설정 필요, 초기 설치 복잡함

4. α, β -CROWN 강점 및 한계

강점: α, β -CROWN 은 VNN-COMP 에서 여러 차례 우승한 도구로, 대형 네트워크에서도 빠른 검증이 가능하다. Linear relaxation 기반의 불완전 검증으로 빠르게 unsat 을 판별하고, 필요한 경우에만 branch-and-bound 로 넘어가는 구조 덕분에 효율적이다. YAML 기반 설정 파일과 VNNLib 표준 형식을 지원하여 다양한 모델과 속성에 범용적으로 적용 가능하다.

한계: 초기 설치 과정이 복잡하며, 서브모듈(auto_LiRPA) 설정 등 환경 구성에 어려움이 있었다. 또한 작은 모델에서는 Marabou 보다 오히려 느릴 수 있으며, linear relaxation 의 특성상 수치적 오차로 인해 결과가 Marabou 와 다를 수 있다.